

BNPL 信用 風險分類與預測

統計方法與資料採礦期末報告

Group 4

組員：張博勛、盧宸立、陳霆翰、陳柏宇

目錄

01

資料集概述

02

探索性資料分析 EDA

03

資料品質檢查

04

資料前處理

05

統計檢定與特徵篩選

06

建立模型

07

評估模型

08

解釋模型

09

結論

資料集概述

先買後付（Buy Now, Pay Later, 簡稱 BNPL）是全球發展最迅速的金融科技領域之一。
此合成資料集模擬了 2023 至 2024 年間、跨越 6 個國家的 10,345 筆 BNPL 交易紀錄，
專為建構信用風險與違約預測模型所設計。

10,345

原始觀測值

17 → 21

原始 → 拆解後欄位

default_flag

目標變數（違約標記）

6 Countries

2023–2024

客戶會不會違約

預測目標

實用價值

主題選擇原因

探索性資料分析 EDA

透過對 Buy Now Pay Later 資料集進行探索性數據分析（EDA），我們深入剖析特徵間的潛在關聯與資料分佈結構，為後續的統計檢定與特徵篩選奠定基礎。

在資料品質檢查中，我們發現此合成資料集存在若干抽樣偏誤：

- 月薪未依國家區分
- 信用分數統一使用美國 FICO 範圍
- 違約比例偏高（39%）

顯示該資料集不適用於實務風控，但仍可供統計檢定與模型練習使用。

變數類型分類

分類	變數	備註
Category (類別型)	employment_type, product_category, location, transaction_is_weekend	無大小之分的群組
Ordinal (順序型)	bnpl_installments, missed_payments	離散整數，視為有序類別
Interval (區間型)	transaction_year, transaction_month, transaction_day, transaction_dayofweek	由 transaction_date 拆解而來
Ratio (比率型)	age, monthly_income, purchase_amount, repayment_delay_days, app_usage_frequency, debt_to_income_ratio	具有絕對零點
Target	default_flag	二元分類目標（0/1）
冗餘（刪除）	user_id, risk_score, credit_score, customer_segment	與 target 意義重疊或無關

※ 原始 transaction_date 已拆解為年/月/日/星期幾/是否週末五個欄位後刪除。

※ 風險評分 risk_score, 標準信用評分 credit_score, 客戶風險分群 customer_segment 意義上太接近 default_flag，判定為冗餘變數。

缺失值 & 離群值 & 重複值


缺失值：0

重複值：0


標籤雜訊：無 (default_flag 僅含 0 和 1)

離群值分析結論：

- risk_score 的離群值違約率(3.2%)遠低於整體(39%)
- monthly_income 的離群值違約率(8%)也偏低
- missed_payments / repayment_delay_days 離群值 100% 違約
- debt_to_income_ratio 離群值違約率(47%)與整體差異不大




實際違約標記 default_flag



未違約與違約比約為 6:4（60.95% : 39.05%）。

現實資料中通常違約比率極低（個位數 %），此資料集設計為大致平衡，提供充足的違約樣本供統計檢定與模型訓練使用。

受雇狀況 employment_type




受雇狀況對違約比率影響較大：

- Self-Employed 違約率最低（26.2%）
- Salaried 次低（32.7%）
- Student 和 Unemployed 違約率接近 49%

學生與無業者的違約風險約為自雇者的兩倍。

客戶風險分群 customer_segment

客戶各風險分群與違約關係





高風險客群之真實違約率顯著偏高（49.6%），顯示客戶風險分群的方式有發揮其作用。

⚠ 冗餘變數

customer_segment 的分群邏輯與 default_flag 高度相關，直接用於預測會造成 data leakage。已在前處理階段移除。

標準信用評分 credit_score





⚠ 冗餘變數

credit_score 與 risk_score 和 customer_segment 高度相關，已在前處理階段移除。

資料集中標準信用評分呈現右尾分布（FICO 300–850），中位數 403，顯示資料中有相當比例的人信用不佳。未違約組的箱體與中位數高於違約組，但違約組中仍有許多高信用分數的離群值，代表傳統信用分數高的人在 BNPL 場景中依然可能發生違約。單純依賴傳統信用評分進行風控仍具風險。

各國的 credit_score 分布幾乎一致（中位數差距 < 15 分），顯示生成器統一使用美國 FICO 標準，跨國預測上屬於嚴重偏誤。



月收入 Monthly_income



- 月收入呈現右偏態，平均數 (\$35,053) 大於中位數 (\$23,800)，低收入者較多。
- 未違約組的月收入箱體及中位數皆大於違約組，可見未違約組月收入整體較高，但在違約組也有較高收入者存在。
- 就業狀態與月薪中位數的關係符合常識：



Self-Employed (\$60,825) > Salaried (\$50,836) > Student (\$15,427) > Unemployed (\$10,086)

分期期數 bnpl_installments





- 分期期數平均分布在 3, 6, 9, 12 期，而在未違約以及違約組也是平均分布。
- Mann-Whitney U 檢定 $p = 0.183$ ，不顯著。
- 在最終特徵篩選中未通過門檻，但仍歸類為 Ordinal 變數。

逾期天數 repayment_delay_days





- 整體逾期天數呈現雙峰結構，中位數 (9) 大於平均數 (8.74)，應是大量 0 天拉低平均。
- 在違約組的逾期天數箱體及中位數都高於未違約組，但未違約組也存在逾期高於 30 天的離群值。

過去漏繳分期付款的總次數 missed_payments






- 過去漏繳分期付款的次數整體集中在 0–2 次，只有少數人有大量漏繳的情況。
- 未違約組過去未漏繳的比例 (42.5%) 高於違約組 (25.4%)，而違約組漏繳分期付款的次數顯著高於未違約組，顯示過去有漏繳記錄的人比較容易違約。

債務收入比 debt_to_income_ratio



- 債務收入比整體呈現右尾分布，平均數 (0.18) 大於中位數 (0.14)，顯示多數人的財務狀況良好，但也有少數人來到 0.7 以上。
- 未違約組的箱體及中位數低於違約組，顯示違約的人整體來說財務壓力較大，但兩組都有大量離群值，代表即便債務高昂也有人願意積極還款。



其他差異微小變數



風險評分 risk_score

⚠ 冗餘變數

risk_score與default_flag 高度相關
(Spearman 0.39)，已在前處理階段移除。



- 風險評分整體呈現近似常態的鐘形分佈，主要集中在 150–300 之間。
- 未違約組的風險評分箱體及中位數皆低於違約組，符合風險評分越高、實際違約機率上升的預期，但違約組有許多低風險離群值，屬於風控中最危險的 False Negative 族群。

資料前處理流程

1

Train/Test 切割

80/20 分層抽樣 (stratify=default_flag)
訓練集 8,276 筆 / 測試集 2,069 筆

2

刪除冗餘變數

移除 user_id, risk_score, credit_score,
customer_segment → 剩餘 16 個特徵

3

統計檢定篩選特徵

僅使用訓練集進行假設檢定
(防止 data leakage)

4

保留通過篩選的 9 個特徵

employment_type, product_category,
missed_payments, transaction_dayofweek,
age, monthly_income, purchase_amount,
repayment_delay_days, debt_to_income_ratio

5

依模型需求分別編碼

RF / XGBoost : One-Hot Encoding
DNN : Winsorization + One-Hot + StandardScaler

三種模型的前處理

Random Forest

One-Hot Encoding (employment_type, product_category)

保留離群值、不做標準化

最終特徵數量：16 (含 One-Hot 展開)

XGBoost / LightGBM

同 Random Forest 前處理

樹模型對尺度不敏感

最終特徵數量：16

DNN (MLP)

① Winsorization 截斷 (99 百分位)

② One-Hot Encoding

③ StandardScaler 標準化

最終特徵數量：16

Categorical 特徵分析（卡方檢定 + WoE/IV）

H₀：此變數與違約行為獨立 H₁：此變數與違約行為相依

顯著水準 $\alpha = 0.05$ （卡方），保留門檻： $p < 0.1$ 或 $IV > 0.01$

※ 僅使用訓練集 (n = 8,276) 進行檢定

特徵變數	Chi ² 統計量	p-value	IV 值	保留?
employment_type	346.81	7.31e-75	0.1814	✔ Yes
product_category	10.03	0.0399	0.0051	✔ Yes
transaction_is_weekend	0.61	0.433	0.0003	✘ No
location	2.94	0.7085	0.0015	✘ No

分析：

employment_type 的卡方值極高且 IV=0.18（中等預測力），為最重要的類別特徵。

product_category 卡方 p=0.04 達顯著（雖 IV 僅 0.005），故保留。

location 和 transaction_is_weekend 均不顯著且 IV 極低，移除。

數值特徵分析 (Mann-Whitney U Test)

由於數值特徵包含序數型變數（如 missed_payments），對其計算均值在統計上缺乏意義。此外，多數連續型特徵的母體分佈為偏態且伴隨離群值，均值難以代表分佈的集中趨勢，比較均值的實務價值有限。因此採用 Mann-Whitney U 檢定，以排序為基礎比較兩組分佈的整體差異。

假設設定（針對每一個數值特徵）：

H_0 ：違約組（default_flag = 1）與正常組（default_flag = 0）在該特徵上的分佈相同

H_1 ：兩組的分佈有顯著差異

顯著水準 $\alpha = 0.10$ （採用較寬鬆門檻進行特徵篩選）

※ 僅使用訓練集 ($n = 8,276$)，不含冗餘變數 (risk_score, credit_score, customer_segment)

Mann-Whitney U Test 結果

類型	特徵變數	p-value	顯著性
Ordinal	missed_payments	3.49e-104	✔ Yes
Ordinal	bnpl_installments	0.1832	✘ No
Interval	transaction_dayofweek	0.0965	✔ Yes
Interval	transaction_year	0.4215	✘ No
Interval	transaction_month	0.5022	✘ No
Interval	transaction_day	0.2444	✘ No
Ratio	repayment_delay_days	4.32e-122	✔ Yes
Ratio	monthly_income	1.00e-107	✔ Yes
Ratio	debt_to_income_ratio	4.01e-85	✔ Yes
Ratio	purchase_amount	2.43e-27	✔ Yes
Ratio	age	1.30e-12	✔ Yes
Ratio	app_usage_frequency	0.942	✘ No

7 個特徵通過篩選（ $p < 0.1$ ），5 個不通過。bnpl_installments、transaction_year/month/day、app_usage_frequency 被篩除。

Spearman 相關係數檢查

將篩選後通過的 7 個連續型/序數型變數計算 Spearman 相關係數矩陣，檢查是否存在高度共線性（ $|r| \geq 0.85$ ）。

	missed_payments	txn_dow	age	income	purchase	delay_days	DTI
missed_payments	1	0.01	0	-0.01	0	0.77	0.01
txn_dow	0.01	1	0.01	0	0.01	-0.01	0
age	0	0.01	1	0.2	0.13	0.01	-0.14
income	-0.01	0	0.2	1	0.68	-0.01	-0.76
purchase	0	0.01	0.13	0.68	1	0.02	-0.17
delay_days	0.77	-0.01	0.01	-0.01	0.02	1	0.01
DTI	0.01	0	-0.14	-0.76	-0.17	0.01	1

結論：無任何變數對的 $|r|$ 達到 0.85 門檻。
missed_payments 與 delay_days (0.77)、income 與 DTI (-0.76) 有中度相關但未達共線性標準。
所有 7 個篩選後特徵均保留，無需移除。

特徵篩選結論

原始 17 個欄位 → 經檢定後保留 9 個特徵

類型	保留特徵	篩選依據
Category	employment_type	χ^2 p < 0.001, IV = 0.18
Category	product_category	χ^2 p = 0.04
Ordinal	missed_payments	MWU p $\approx$ 3.5e-104
Interval	transaction_dayofweek	MWU p = 0.097 (< 0.1)
Ratio	age	MWU p $\approx$ 1.3e-12
Ratio	monthly_income	MWU p $\approx$ 1.0e-107
Ratio	purchase_amount	MWU p $\approx$ 2.4e-27
Ratio	repayment_delay_days	MWU p $\approx$ 4.3e-122
Ratio	debt_to_income_ratio	MWU p $\approx$ 4.0e-85

移除的特徵：user_id（無關）、risk_score / credit_score / customer_segment（冗餘）、location / transaction_is_weekend（ χ^2 不顯著）、bnpl_installments / app_usage_frequency（MWU 不顯著）、transaction_year / month / day（MWU 不顯著）

Modeling

使用模型：Random Forest、XGboost、DNN

- 隨機森林對離群值容忍度高，且不易過擬合，很適合拿來當基準模型 (Baseline)。因為違約樣本通常較少（類別不平衡），我們加上 `class_weight='balanced'` 來應對。
- XGBoost 是目前處理表格資料（Tabular Data）的最優選擇，通常能跑出極佳的效能。針對偽陰性代價高的問題，我們使用 `scale_pos_weight` 來增加違約樣本的懲罰權重。
- 深度神經網路 (DNN / MLP)，利用 TensorFlow/Keras 建構標準的多層感知機 (MLP)。

Evaluation

機率校準度 (Probability Calibration)


機率誠實度：如果模型將一群人的預測機率落在 11~20% 區間，那這群人的實際違約率是否真的接近 15% 左右？

泛化程度：如果訓練集的機率誠實度表現良好，但是測試集表現有崩跌現象，檢驗是否發生訓練的過擬合？

1. 分別對 訓練集 與 測試集/驗證集 輸出模型預測的「用戶違約機率值」。
2. 將預測機率依序等距劃分，每隔 10% 作為一個分桶區間（即：0~10%、11~20%、21~30% ... 91~100%）。
3. 計算每個機率區間內的「實際違約人數佔比」（該區間內 `default_flag = 1` 的比例）。



結論：

- 三種模型測試集的分桶機率誠實度表現趨近完美校正，DNN最擬合，其他兩模型其次且差異不大
- 沒有崩跌與過擬合



ROC 和 PR 曲線

掃過所有可能的門檻（從 0 到 1），看模型在每個門檻下的 TPR vs FPR（ROC）和 Precision vs Recall（PR）。曲線下面積越大，代表模型整體的排序能力越好，代表不管你最終選什麼門檻，它都更有能力把違約者排在高機率那端。從圖中可看出三個模型的ROC和PR曲線差異皆不大，DNN具有微幅優勢。



Evaluation

預測表現指標(Accuracy, Precision, Recall, F2-Score)

任務考量: 為落實False Negative(偽陰性)(預測不違約而實際違約)代價極高的商業政策，著重於召回率（Recall），使用F2-Score指標衡量模型

$$F_2 = 5 \times \frac{Precision \times Recall}{4 \times Precision + Recall}$$

這會給予 Recall 兩倍於 Precision 的權重，強迫門檻往低處走，主動抓出更多潛在違約者。


反之，也可能高估風險 (Over-estimation)，如果模型預測 80% 會違約，但實際只有 20% 違約。這會導致公司過度保守，錯殺大量優質客戶，流失市占率與手續費收入。

Evaluation


混淆矩陣

在 0.5 門檻下 隨機森林、XGBoost TP > FN, TN > FP，而 DNN 明顯都預測 0。


在 F2 Score 最佳化門檻下三者都嚴重偏重預測 1。




Confusion Matrix: XGBoost (Optimal Threshold)



Confusion Matrix: DNN (Optimal Threshold)




Confusion Matrix: Random Forest (Optimal Threshold)



Interpretation

使用SHAP(SHapley Additive exPlanations)方法解釋分類模型



以XGBoost為例

三種模型共有高度貢獻輸入特徵:


- Monthly income
- Repayment delay days
- Missed payments
- Debt-to-income ratio

Interpretation

使用SHAP(SHapley Additive exPlanations)方法解釋分類模型

貢獻特徵符合金融直覺邏輯:

- 現金流健康度
 - Monthly income越高->大幅影響預測不會違約
 - Debt-to-income ratio越低->大幅影響預測不會違約
- 歷史信用瑕疵
 - Repayment delay days越高->大幅影響預測會違約
 - Missed payments越多->大幅影響預測會違約



以Random Forest為例

Interpretation

使用此模型、探勘模式結果之前...

前提假設？

- 歷史資料具備未來代表性
 - 經濟環境穩定
 - 消費文化相近
- 客戶特徵資料真實無誤
- BNPL業務機制維持一致
- SHAP假設特徵間的貢獻具備獨立性與可加成性

效果限制？

- 合成訓練集與真實資料有落差
- 機率校準與決策權衡(平衡於偏重"漏報"與"誤報"間)
- 特徵不足以再精進分類
 - 時序性特徵(近期遲繳紀錄...)
 - 壓力特徵(短期信用卡使用行為變化...)
- 捕捉相關性行為訊號不等於因果關係

該不該用？

- 得利用於
 - 輔助授信與風控單位制定適當的業務規則或硬性門檻
 - 作為內部參考，了解高風險客戶被系統拒絕的主要風險因子
- 不應利用於
 - 盲目全自動決策，缺乏人工覆核機制（尤其是面對極端值或資料不足的少數群體）
 - 將模型結果視為絕對的商業政策，而忽略業務面的彈性與客戶體驗

Conclusion

本專案針對 BNPL 合成交易資料集，以 default_flag 作為目標變數來建構違約預測模型。經過統計檢定，我們選出了 9 個有效特徵。結果顯示，違約行為主要受逾期天數和月收入影響，三種模型都學到了這一模式，且方向一致。不過，需要注意的是，模型所捕捉到的是與違約高度相關的行為訊號，而不是真正的根本原因。模型之間整體差異不大，DNN 在機率校準方面表現最好。

在實務中，為了減少漏判違約帶來的重大損失，調低門檻是必要的，但這也會導致誤拒一些好客戶。在實際部署時，必須根據違約損失和客戶價值來尋找平衡點。由於我們使用合成資料，具體的參數無法直接落地。不過，分析流程中的特徵篩選邏輯、門檻選擇策略以及 SHAP 驅動的拒絕原因說明等，都可以應用到真實場景中。

Thank You